

ИССЛЕДОВАНИЕ АДАПТИВНОГО ВЫБОРА КЛЮЧЕВЫХ КАДРОВ ДЛЯ ВЫЧИСЛИТЕЛЬНО-ЭФФЕКТИВНОГО СЕМАНТИЧЕСКОГО КАРТИРОВАНИЯ С ОТКРЫТЫМ СЛОВАРЁМ

А. М. Попов

Университет ИТМО

1 АННОТАЦИЯ

В работе рассматривается проблема вычислительной эффективности семантического картирования с открытым словарём. Исследуется возможность адаптивного выбора ключевых кадров на основе информации о траектории камеры и изменениях наблюдаемой сцены для снижения вычислительных затрат при сохранении качества семантической карты. Исходный код и результаты экспериментов доступны в [GitHub-репозитории](#).

2 МОТИВАЦИЯ

Развитие робототехнических систем, предназначенных для функционирования в средах, ориентированных на человека, таких как жилые и офисные помещения, требует формирования пространственных представлений, содержащих не только геометрическую, но и семантическую информацию об окружающей среде. Такие представления позволяют использовать сведения о расположении, свойствах и взаимосвязях объектов при решении высокоуровневых задач, включая поиск объектов, планирование действий и манипуляцию [1].

Одним из перспективных направлений формирования подобных представлений является семантическое картографирование с открытым словарём (Open-Vocabulary Semantic Mapping), обеспечивающее возможность интерпретации элементов сцены посредством произвольных текстовых запросов без ограничения заранее заданным набором категорий. Однако применение современных нейросетевых моделей для сегментации изображений и извлечения визуально-языковых признаков сопровождается значительными вычислительными затратами, что затрудняет использование таких методов в робототехнических системах, работающих в реальном времени.

Одним из способов повышения вычислительной эффективности является выбор ограниченного набора информативных ключевых кадров для семантической обработки. При этом сокращение числа обрабатываемых кадров может приводить к потере информации об отдельных объектах и снижению полноты и точности семантической карты. В связи с этим актуальной является задача разработки и исследования методов адаптивного выбора ключевых кадров, позволяющих сократить вычислительные затраты при сохранении требуемого качества семантического представления окружающей среды.

3 ПОСТАНОВКА ЗАДАЧИ ИССЛЕДОВАНИЯ

Требуется исследовать методы адаптивного выбора ключевых кадров для вычислительно-эффективного семантического картографирования с открытым словарём, обеспечивающие сокращение вычислительных затрат на нейросетевую обработку при сохранении заданного качества семантического представления окружающей среды.

На вход системы поступает последовательность кадров $V = \{f_0, \dots, f_\tau\}$, где $f_i = (I_i, z_i)$ содержит RGB-изображение $I_i \in \{0, \dots, 255\}^{w \times h \times 3}$ и дополнительные сенсорные измерения z_i , при их наличии.

Предполагается, что геометрический SLAM-модуль оценивает положения камеры $T_i \in SE(3)$ и формирует геометрическое представление среды P . Оценки положения камеры и геометрическая информация используются в процессе построения семантической карты. При этом семантическая обработка выполняется асинхронно и не оказывает непосредственного влияния на работу основного контура локализации.

Результатом работы системы является метрико-семантическая карта $M = \{\mathcal{T}, P, \mathcal{S}\}$, где $\mathcal{T}$ — множество оценённых положений камеры, P — геометрическое представление среды, а $\mathcal{S} = \{s_1, \dots, s_m\}$ — множество семантических элементов карты.

Каждый семантический элемент определяется как $s_j = (G_j, d_j)$, где G_j — геометрическое представление элемента, а $d_j \in \mathbb{R}^D$ — визуально-языковой дескриптор, обеспечивающий сопоставление элемента с произвольными текстовыми запросами.

Для обеспечения работы с открытым словарём определяется оператор

$$R(q, M) \rightarrow \hat{s}, \quad \hat{s} \in \mathcal{S},$$

сопоставляющий текстовый запрос q с соответствующим пространственным элементом карты.

В рамках исследования рассматривается задача выбора подмножества кадров $K_\pi \subseteq V$, направляемых на вычислительно затратную семантическую обработку. Для каждого поступающего кадра f_i формируется вектор признаков

$$x_i = \phi(f_i, T_i, P, M_{i-1}),$$

где ϕ — функция формирования признаков, характеризующих информативность текущего наблюдения относительно ранее построенной карты.

Вектор x_i может включать показатели изменения положения камеры, степени перекрытия текущего наблюдения с ранее обработанными кадрами, новизны наблюдаемой области и полноты семантического представления. Конкретный состав признаков и методы их вычисления являются предметом исследования.

Решение о передаче кадра на семантическую обработку принимается адаптивной политикой

$$a_i = \pi(x_i), \quad a_i \in \{0, 1\},$$

где $a_i = 1$ соответствует выбору кадра для семантической обработки, а $a_i = 0$ — его пропуску.

Таким образом, множество выбранных ключевых кадров определяется как

$$K_\pi = \{f_i \in V \mid \pi(x_i) = 1\}.$$

Требуется определить стратегию π^* , минимизирующую суммарную вычислительную стоимость семантической обработки:

$$\pi^* = \arg \min_{\pi} \sum_{i=0}^{\tau} C_{\text{sem}}(a_i),$$

где $C_{\text{sem}}(a_i)$ — вычислительные затраты, связанные с принятым решением.

При предположении приблизительно постоянной стоимости обработки одного выбранного кадра задача сводится к минимизации количества кадров,

направляемых на семантическую обработку:

$$\pi^* = \arg \min_{\pi} |K_{\pi}|.$$

Минимизация выполняется при условии сохранения заданного качества семантического представления, определяемого эмпирическим, путем обработки избыточного числа кадров:

$$Q_{OV}(M_{\pi}) \geq Q_{OV}^{\min},$$

где M_{π} — карта, построенная с использованием выбранного множества кадров K_{π} , а Q_{OV} — показатель качества семантического представления, оцениваемый по точности семантической сегментации и сопоставления пространственных элементов с текстовыми запросами.

Для обеспечения применимости метода в онлайн-системах выбор кадров должен выполняться последовательно, с использованием информации, доступной на момент принятия решения. Вычислительно затратная семантическая обработка осуществляется асинхронно относительно основного контура отслеживания.

Гипотеза: адаптивный выбор кадров на основе их информативности и текущего состояния карты позволяет сократить количество запусков нейросетевых моделей по сравнению с периодическим выбором кадров при сохранении сопоставимого качества семантического представления окружающей среды.

4 ОБЗОР ИЗВЕСТНЫХ ПОДХОДОВ

В существующих исследованиях выбор ключевых кадров для семантического картографирования реализуется на основе различных критериев, определяющих необходимость обработки очередного наблюдения. Рассматриваемые подходы можно разделить на три группы:

Геометрически обусловленный выбор ключевых кадров. В OVO (Open-Vocabulary Online Semantic Mapping for SLAM) [2] построение трёхмерной семантической карты выполняется асинхронно по RGB-D ключевым кадрам, поступающим от базовой SLAM-системы. Для формирования семантического представления используются SAM2.1 [3] и SigLIP [4], обеспечивающие сегментацию наблюдений и извлечение визуально-языковых дескрипторов. Отбор кадров для семантической обработки осуществляется с фик-

сированной периодичностью из ключевых кадров, поступающих от SLAM-пайплайна, в виде ORB-SLAM3[5], без непосредственной оценки их семантической информативности. Преимуществами подхода являются модульность и независимость семантического конвейера от геометрической локализации, недостатками - избыточная обработка повторяющихся наблюдений и возможность пропуска информативных кадров при фиксированной периодичности отбора.

В RADIO-ViPE [6] ключевые кадры выбираются на основе относительного движения камеры, оцениваемого посредством взвешенного плотного оптического потока. Кадр включается в граф факторов при превышении заданного порога движения. Для выбранных кадров вычисляются нейросетевая глубина и плотные визуально-семантические признаки RADSeg [7], используемые при оптимизации траектории и построении карты. Таким образом, выбор кадров позволяет ограничивать количество вычислительно затратных операций, однако ориентирован преимущественно на обеспечение геометрической локализации и не учитывает непосредственно вклад наблюдений в качество семантического представления.

Выбор ключевых кадров на основе пространственного покрытия. В работе KeySG [8] исследуется задача сохранения пространственной и визуальной информации при сокращении количества кадров, используемых для формирования трёхмерного графа сцены. Авторы предлагают кластеризацию поз камеры посредством HDBSCAN[9] и сравнивают её с шестью стратегиями: равномерной и случайной выборкой, кластеризацией визуальных признаков DINOv2 [10], адаптивным DBSCAN, локальной и глобальной оптимизацией совместной видимости объектов.

Семантически обусловленный выбор ключевых кадров. В FOUND-IT [11] предложен подход к построению иерархического трёхмерного графа сцены с отложенной семантической обработкой. Геометрическое картографирование осуществляется посредством VGGT-SLAM 2.0 [12], где ключевые кадры выбираются на основе параллакса. Для каждого ключевого кадра вычисляется визуально-языковой дескриптор, сохраняемый в памяти системы. При поступлении текстового запроса кадры ранжируются по косинусному сходству их дескрипторов с запросом, после чего релевантные наблюдения направляются в SAM3 для сегментации объектов. Обработка дополнительных кадров выполняется с учётом видимости ранее обнаруженных объектов. Та-

кой подход позволяет сократить количество запусков сегментационной модели и формировать детальное семантическое представление по мере поступления запросов. Однако отбор кадров для семантической сегментации зависит от конкретного запроса, тогда как при построении универсальной карты с открытым словарём будущие запросы заранее неизвестны.

5 ОПИСАНИЕ БАЗОВОГО РЕШЕНИЯ

В качестве базовой архитектуры для проведения исследования выбран OVO, обеспечивающий построение трёхмерного семантического представления с открытым словарём на основе RGB-D ключевых кадров геометрического SLAM. Модульная архитектура OVO позволяет исследовать стратегии выбора кадров для семантической обработки независимо от алгоритма оценки траектории камеры, но при этом есть возможность использовать GT, полученный в результате его работы.

Предлагается дополнить существующую архитектуру модулем адаптивного выбора ключевых кадров для нейросетевой семантической обработкой. Модуль принимает видеопоток, оценивает камеры и определяет необходимость их передачи в семантический конвейер. При этом используемые модели сегментации и извлечения визуально-языковых признаков остаются неизменными. Общая структура показана на [Рисунке 1](#).

В качестве базовой стратегии сравнения используется равномерный периодический отбор кадров, соответствующий исходному принципу работы OVO. Для исследования влияния геометрической информативности предполагается реализовать пороговый выбор по изменению позы камеры.

6 МЕТРИКИ ОЦЕНКИ

Для экспериментального исследования методов адаптивного выбора ключевых кадров необходимо оценить вычислительную эффективность семантического картографирования, качество формируемого семантического представления и информативность выбранных кадров. Основной задачей является минимизация вычислительных затрат при сохранении заданного качества семантической карты:

$$\min_{\pi} C(\pi), \quad Q_{\text{OV}}(M^{\pi}) \geq Q_{\text{OV}}(M^{\text{all}}) - \varepsilon,$$




Рисунок 1 — На вход системы поступает последовательность кадров $V = \{f_0, \dots, f_T\}$, где $x_i = (I_i, z_i)$ содержит RGB-изображение $I_i \in \{0, \dots, 255\}^{w \times h \times 3}$ и дополнительные сенсорные измерения z_i , при их наличии. SLAM-модуль оценивает положения камеры $T_i \in SE(3)$ и формирует геометрическое представление среды P . Семантическая обработка выполняется асинхронно, стратегия $\pi(x_i)$ выбирает ключевые кадры. Результатом работы является метрико-семантическая карта $M = \{\mathcal{T}, P, S\}$, где $\mathcal{T}$ — множество оценённых положений камеры, P — геометрическое представление среды, а $S = \{s_1, \dots, s_m\}$ — множество семантических элементов карты. Каждый семантический элемент определяется как $s_j = (G_j, d_j)$, где G_j — геометрическое представление элемента, а $d_j \in \mathbb{R}^D$ — визуально-языковой дескриптор.

где $C(\pi)$ — вычислительная стоимость стратегии выбора кадров, M^π — карта, построенная с использованием стратегии π , M^{all} — карта при обработке всех доступных ключевых кадров, Q_{OV} — показатель качества семантического представления, а ε — допустимое снижение качества.

Экспериментальное исследование предполагается проводить на наборе данных **Replica** [13], содержащем синтетические сцены помещений с RGB-D наблюдениями и эталонной семантической разметкой. Использование стандартного подмножества из восьми сцен позволяет сопоставлять результаты с опубликованными экспериментами OVO.

Вычислительная эффективность. Для оценки вычислительных затрат предполагается измерять суммарное время нейросетевой обработки, среднее время обработки одного выбранного кадра, затраты на выполнение стратегии отбора, а также использование GPU-памяти. Дополнительно определяется доля обработанных кадров (Sampling Ratio):

$$R_{\text{sample}} = \frac{|K_\pi|}{|K|},$$

где K_π — множество выбранных для семантической обработки кадров, K — исходное множество ключевых кадров геометрического SLAM.

Снижение вычислительных затрат оценивается относительно базовой стратегии:

$$\eta_C = 1 - \frac{C(\pi)}{C(\pi_{\text{base}})},$$

где π_{base} — стратегия, используемая в исходной реализации OVO.

Качество семантического представления. Основной метрикой предлагается использовать mean Intersection over Union (mIoU), характеризующую качество семантической сегментации трёхмерной карты относительно эталонной разметки:

$$\text{mIoU} = \frac{1}{|\mathcal{C}|} \sum_{c \in \mathcal{C}} \frac{|P_c \cap G_c|}{|P_c \cup G_c|},$$

где $\mathcal{C}$ — множество оцениваемых семантических категорий, P_c — множество элементов карты, отнесённых к категории c , G_c — соответствующее множество элементов эталонной разметки.

Для оценки влияния стратегии выбора кадров на качество семантической карты определяется изменение mIoU относительно обработки всех ключевых кадров:

$$\Delta Q_{\text{OV}} = \text{mIoU}(M^\pi) - \text{mIoU}(M^{\text{all}}).$$

Информативность выбранных кадров. В качестве дополнительных метрик могут использоваться критерии, рассмотренные в KeySG [8]:

Object Recall — доля уникальных объектов эталонной сцены, наблюдаемых хотя бы на одном выбранном кадре;

Geometric Coverage — доля точек поверхности полной трёхмерной реконструкции, находящихся на расстоянии не более $\tau = 0.05$ м от разреженного облака точек, полученного по выбранным кадрам.

Данные метрики позволяют оценить сохранение визуальной и пространственной информации, однако не характеризуют непосредственно точность семантической сегментации и качество визуально-языковых дескрипторов.

Таким образом, на наборе данных Replica предполагается исследовать зависимость качества семантического представления от количества выбранных кадров и вычислительных затрат. Основным критерием эффективности

является сокращение вычислительной стоимости семантического картографирования при допустимом снижении mIoU. Дополнительные метрики позволяют оценить, насколько геометрическое покрытие и полнота наблюдения объектов связаны с качеством формируемой семантической карты.

7 ЭКСПЕРИМЕНТАЛЬНОЕ ИССЛЕДОВАНИЕ

Экспериментальная среда была самостоятельно развёрнута и настроена на арендованном удалённом GPU-сервере облачного провайдера Selectel. Аппаратная конфигурация и программное окружение представлены в [Таблице 1](#).

Таблица 1 — Характеристики вычислительной среды

Параметр	Значение
Операционная система	Ubuntu 24.04.3 LTS (x86_64)
Процессор	8 vCPU
Оперативная память	32 ГБ
Графический ускоритель	NVIDIA GeForce RTX 4090
Видеопамять	24 ГБ
Драйвер NVIDIA	580.65.06
Поддерживаемая версия CUDA	13.0
Версия Python	3.11.17
Версия PyTorch	2.5.1+cu124
CUDA Runtime (PyTorch)	12.4

Экспериментальное исследование проводится на основе системы OVO с использованием набора данных Replica. На начальном этапе выполнены проверка корректности развёртывания программного комплекса и получение базовых показателей качества семантического картографирования и вычислительной производительности.

Сбор данных профилирования

Для оценки вычислительных затрат использовался встроенный механизм профилирования OVO. Измерение времени отдельных операций осуществляется посредством декоратора `profil`, который регистрирует продолжительность выполнения соответствующих методов. Перед началом и после

завершения измеряемой операции выполняется синхронизация CUDA, позволяющая учитывать асинхронное выполнение вычислений на графическом ускорителе.

В процессе работы системы регистрируются следующие показатели:

- `frame_id` — идентификатор кадра, связанного с событием семантической обработки;
- `t_seg` — время получения сегментационных масок;
- `t_obj` — время сопоставления и отслеживания объектов;
- `t_clip` — время извлечения семантических признаков с использованием CLIP;
- `t_up` — время обновления семантических дескрипторов объектов;
- `n_matches` — количество сопоставленных элементов, зарегистрированное на этапе обработки объектов;
- `n_obj` — количество новых объектов, зарегистрированных при обработке кадра;
- `vram` — объём видеопамяти, выделенной средствами PyTorch, ГБ;
- `ram` — объём оперативной памяти, занимаемой процессом, ГБ;
- `spf` — время обработки семантического шага, с;
- `avg_fps` — усреднённый показатель производительности, вычисляемый системой;
- `max_vram` — максимальный объём видеопамяти, выделенной средствами PyTorch, ГБ;
- `max_ram` — максимальное зарегистрированное потребление оперативной памяти процесса, ГБ.

Значения сохраняются в отдельных текстовых файлах с расширением `.log`. Показатель `n_obj` используется внутренним механизмом логирования, но не записывается в отдельный файл. В рассматриваемой конфигурации также предусмотрен журнал `t_seg`, однако соответствующее измерение не активировано.

Регистрация временных характеристик выполняется на двух этапах: при получении масок и сопоставлении объектов, а также при извлечении и обновлении семантических признаков. Поскольку второй этап может выполняться с задержкой через очередь обработки ключевых кадров, количество

записей в журнале `frame_id` соответствует суммарному количеству событий обоих этапов.

Обработка результатов профилирования

Для автоматизации анализа вычислительных затрат разработан скрипт `analyze_performance.py`, выполняющий постобработку журналов после завершения эксперимента. Для каждой последовательности кадров вычисляются количество измерений, среднее арифметическое, медиана, минимальное и максимальное значения, 95-й и 99-й процентиля, а также сумма значений. Поскольку идентификаторы кадров сохраняются без указания типа события, однозначное соответствие между измерениями разных этапов и исходными кадрами не гарантируется. Поэтому результаты объединяются по порядковому номеру измерения без неподтверждённой привязки к конкретному кадру. По результатам обработки автоматически формируются следующие файлы:

- `performance_summary.json` — агрегированные статистические показатели, суммарные вычислительные затраты и диагностические предупреждения;
- `performance_samples.csv` — таблица отдельных измерений с их порядковыми индексами;
- `timing.png` — график изменения времени выполнения основных этапов семантической обработки;
- `memory.png` — график изменения потребления оперативной и видеопамяти.

Разработанный инструмент обеспечивает единообразную обработку результатов экспериментов при различных частотах семантического анализа кадров. Полученные статистические показатели используются для сопоставления вычислительных затрат с качеством построенной семантической карты.

7.1 Эксперимент 0. Проверка работоспособности OVO

Целью эксперимента является проверка корректности развёртывания OVO, установленных зависимостей, предобученных нейросетевых моделей и набора данных Replica перед проведением полноценных исследований.

Для сокращения времени выполнения обработка ограничена первыми 20 кадрами сцены office0.

Основные параметры эксперимента:

- набор данных — Replica;
- сцена — office0;
- количество кадров — 20;
- периодичность семантической обработки `segment_every` — 10.

Проверочный запуск успешно завершён. Система корректно загрузила набор данных и нейросетевые модели, после чего выполнила обработку заданной последовательности.

Полученные показатели вычислительной производительности представлены в [Таблице 2](#).

Таблица 2 — Результаты проверочного запуска OVO

Метрика	Значение
Средняя частота обработки, FPS	0.441
Среднее время SAM, с	0.635
Среднее время CLIP, с	0.725
Среднее время обработки объектов, с	0.378
Среднее использование VRAM, ГБ	8.64
Максимальное использование VRAM, ГБ	10.77
Полное время запуска, с	50.70

Результаты подтверждают работоспособность экспериментального стенда. Ввиду небольшой длины последовательности полученные временные характеристики используются исключительно для проверки функционирования системы и не рассматриваются в качестве базовых показателей производительности.

7.2 Эксперимент 1. Базовая оценка OVO на Replica

Целью эксперимента является определение базовых показателей качества семантического картографирования и вычислительной производительности системы OVO на последовательности `office0` набора данных Replica.

Полученные результаты используются в качестве исходной точки для исследования влияния частоты семантической обработки кадров на качество формируемой карты и вычислительные затраты.

Основные параметры эксперимента:

- стратегия выбора кадров — фиксированная периодическая;
- период семантической обработки `segment_every` — 10;

Эксперимент включал три этапа: построение семантической карты, формирование предсказанной семантической разметки эталонного облака точек и вычисление метрик качества. Дополнительно выполнялся сбор временных характеристик отдельных компонентов семантического конвейера и показателей потребления памяти.

7.2.1 Качество семантического представления

Для количественной оценки качества сформированной семантической карты использовались метрики средней полноты пересечения и объединения (`mIoU`), средней точности по классам (`mAcc`), а также их варианты с учётом частоты классов (`f-mIoU` и `f-mAcc`).

Результаты эксперимента представлены в [Таблице 3](#). Для справочного сравнения также приведены значения, опубликованные авторами OVO для различных вариантов интеграции семантического картографирования с геометрическими SLAM-системами.

Таблица 3 — Качество семантического картографирования на наборе данных Replica

Эксперимент	<code>mIoU</code> , %	<code>mAcc</code> , %	<code>f-mIoU</code> , %	<code>f-mAcc</code> , %
OVO-mapping (статья)	27.00	39.10	—	—
OVO-Gaussian-SLAM (статья)	27.10	38.60	—	—
OVO-ORB-SLAM2 (статья)	25.60	39.00	—	—
OVO (Fixed-10, <code>office0</code>)	24.90	32.80	42.00	54.00

Следует отметить, что результаты авторов OVO получены на наборе сцен Replica, тогда как в настоящем эксперименте используется только последовательность office0. В связи с различиями в составе тестовых данных приведённое сравнение носит справочный характер и не позволяет непосредственно оценить отклонение качества от результатов оригинальной реализации.

7.2.2 Вычислительная производительность

Для исследования вычислительной производительности использовались журналы встроенного механизма профилирования OVO. Их обработка выполнялась разработанным скриптом `analyze_performance.py`, рассчитывающим статистические характеристики продолжительности отдельных операций и потребления памяти.

Для каждого основного этапа семантического конвейера было получено 200 временных измерений.

В [Таблице 4](#) приведены средние значения, 95-й перцентиль и суммарное время выполнения профилируемых операций.

Таблица 4 — Временные характеристики компонентов семантического конвейера OVO

Компонент	Среднее, с	P95, с	Сумма, с
Получение масок (SAM)	0.448	0.640	89.530
Сопоставление объектов	0.074	0.103	14.818
Извлечение признаков CLIP	0.122	0.240	24.370
Обновление дескрипторов	0.001	0.002	0.149
Всего	—	—	128.867

Суммарное время профилируемых этапов семантической обработки составило 128.867 с. При этом наибольшая доля вычислительных затрат приходится на получение сегментационных масок — 69.5 %. Извлечение признаков CLIP составляет 18.9 %, сопоставление объектов — 11.5 %, обновление дескрипторов — менее 0.2 %.

Полученное распределение указывает на то, что основная вычислительная нагрузка сосредоточена на этапах получения сегментационных масок и извлечения семантических признаков. Следовательно, изменение ча-

стоты выполнения этих операций представляет интерес как способ повышения вычислительной эффективности системы.

Следует учитывать, что суммарное время профилируемых операций не эквивалентно полному времени выполнения программы, поскольку не включает все вспомогательные вычисления, операции ввода-вывода и накладные расходы.

Дополнительные показатели производительности и потребления памяти приведены в **Таблице 5**.

Таблица 5 — Дополнительные показатели производительности и потребления памяти

Метрика	Значение
Зарегистрированный показатель avg_fps	0.969
Среднее значение SPF, с	0.641
P95 значения SPF, с	0.850
Средний объём выделенной VRAM, ГБ	11.253
Максимальный объём выделенной VRAM, ГБ	11.532
Средний объём RAM процесса, ГБ	3.198
Максимальный объём RAM процесса, ГБ	3.606

Показатель avg_fps отражает производительность, зарегистрированную внутренним механизмом OVO, и не интерпретируется как частота обработки всех входных кадров без дополнительного анализа реализации соответствующего измерения.

Объём видеопамати определялся средствами PyTorch и характеризует память, выделенную его механизмом управления памятью, а не полное потребление видеопамати графического ускорителя.

7.2.3 Выводы по эксперименту

Проведённое профилирование позволило определить распределение вычислительных затрат между основными этапами семантического конвейера. Установлено, что наибольшую долю измеренного времени занимает получение сегментационных масок, вследствие чего сокращение частоты семантической обработки потенциально может обеспечить существенное уменьшение вычислительных затрат.

Полученные значения качества и производительности приняты в качестве базовых для последующего эксперимента, направленного на исследование влияния периодичности обработки кадров на вычислительную эффективность и качество семантической карты.

7.3 Эксперимент 2. Исследование влияния частоты семантической обработки кадров

Целью эксперимента является исследование зависимости вычислительных затрат и качества семантического картографирования от периодичности обработки входных кадров системой OVO. Основные параметры эксперимента:

- стратегия выбора кадров — фиксированная периодическая;
- исследуемые значения `segment_every` — 5 и 20;

При значениях `segment_every`, равных 5, 10 и 20, количество семантически обработанных кадров составило соответственно 400, 200 и 100, что соответствует 20 %, 10 % и 5 % исходной последовательности. Эксперимент включал построение семантической карты, вычисление метрик её качества и обработку журналов профилирования.

7.3.1 Качество семантического представления

Для оценки влияния частоты обработки кадров на качество семантической карты использовались метрики `mIoU`, `mAcc`, `f-mIoU` и `f-mAcc`. Результаты представлены в [Таблице 6](#).

Таблица 6 — Зависимость качества семантической карты от периодичности обработки кадров

Конфигурация	<code>mIoU</code> , %	<code>mAcc</code> , %	<code>f-mIoU</code> , %	<code>f-mAcc</code> , %
Fixed-5	22.80	30.60	47.10	60.30
Fixed-10	24.90	32.80	42.00	54.00
Fixed-20	26.70	35.60	48.60	61.60

Наибольшие значения всех рассматриваемых метрик получены при обработке каждого двадцатого кадра. Для конфигурации Fixed-20 значение

mIoU составило 26.70 %, что на 1.80 процентного пункта превышает результат базовой конфигурации Fixed-10 и на 3.90 процентного пункта — результат Fixed-5.

Аналогичная зависимость наблюдается для mAcc: при увеличении периода обработки с 5 до 20 кадров значение метрики возросло с 30.60 % до 35.60 %.

Для частотно-взвешенных метрик зависимость оказалась немонотонной. В частности, конфигурация Fixed-10 продемонстрировала меньшие значения f-mIoU и f-mAcc по сравнению с обеими альтернативными конфигурациями.

Таким образом, увеличение количества семантически обработанных кадров в рассматриваемом эксперименте не привело к повышению качества карты. Полученный результат указывает на то, что информативность выбранных кадров может иметь большее значение, чем их количество. Вместе с тем для подтверждения данной гипотезы необходимы дополнительные эксперименты с различными стратегиями выбора кадров.

7.3.2 Вычислительная производительность

Для сравнения вычислительных затрат использовалось суммарное время выполнения профилируемых этапов семантической обработки, рассчитанное по журналам OVO.

Результаты представлены в **Таблице 7**.

Таблица 7 — Вычислительные затраты при различной периодичности семантической обработки

Показатель	Fixed-5	Fixed-10	Fixed-20
Семантически обработано кадров	400	200	100
Доля входных кадров, %	20	10	5
Суммарное время семантики, с	245.330	128.867	68.465
SAM P95, с	0.650	0.640	0.620
Пиковая VRAM, ГБ	11.51	11.53	11.54

При увеличении периода семантической обработки с 5 до 20 кадров суммарное время профилируемых операций сократилось с 245.330 до 68.465 с, то есть на 72.1 %. Относительно базовой конфигурации Fixed-10

использование Fixed-20 обеспечило сокращение измеренных вычислительных затрат на 46.9 %. При этом переход от Fixed-10 к Fixed-5 сопровождался увеличением затрат на 90.4 %.

Для дополнительного сравнения вычислительной эффективности определим удельную стоимость одного семантического шага:

$$\overline{C}_{\text{sem}} = \frac{C_{\text{sem}}}{N_{\text{seg}}}, \quad (1)$$

где C_{sem} — суммарное время профилируемых семантических операций, N_{seg} — количество семантически обработанных кадров.

Результаты расчёта приведены в **Таблице 8**.

Таблица 8 — Удельная вычислительная стоимость семантической обработки

Показатель	Fixed-5	Fixed-10	Fixed-20
Среднее время на семантический шаг, с	0.613	0.644	0.685

Полученные значения показывают, что средняя стоимость одного семантического шага остаётся сопоставимой для всех трёх конфигураций. Следовательно, сокращение суммарных затрат преимущественно достигается за счёт уменьшения количества семантических обновлений, а не ускорения отдельных операций.

При этом пиковое потребление видеопамати практически не изменяется и составляет около 11.5 ГБ. Таким образом, снижение частоты обработки позволяет уменьшить суммарные временные затраты, но в рассматриваемых конфигурациях не приводит к существенному сокращению пикового объёма выделенной видеопамати.

Следует учитывать, что приведённые временные характеристики представляют сумму профилируемых операций и не эквивалентны полному времени выполнения системы.

7.3.3 Выводы по эксперименту

В результате эксперимента установлено, что периодичность семантической обработки кадров оказывает существенное влияние на вычислительные затраты OVO. Полученные результаты показывают, что увеличение частоты семантической обработки не гарантирует повышения качества карты.

Это позволяет рассматривать выбор кадров как самостоятельную задачу оптимизации, в которой необходимо учитывать не только количество обработанных наблюдений, но и их потенциальную информативность. Вместе с тем эксперимент проводился на одной последовательности и с использованием только фиксированных периодических стратегий. Поэтому полученные результаты не позволяют сделать вывод о превосходстве обработки каждого двадцатого кадра в общем случае.

7.4 Выводы по экспериментам

Исследование влияния периодичности семантической обработки показало, что увеличение количества обрабатываемых кадров не гарантирует повышения качества карты. При переходе от обработки каждого пятого кадра к обработке каждого двадцатого суммарное время семантических операций сократилось с 245.33 до 68.47 с, или на 72.1 %. При этом значение mIoU увеличилось с 22.80 % до 26.70 %. Пиковое потребление видеопамати во всех конфигурациях оставалось практически неизменным и составляло около 11.5 ГБ.

Полученные результаты свидетельствуют о наличии потенциала для сокращения вычислительных затрат за счёт уменьшения частоты семантической обработки без обязательного ухудшения качества карты. Вместе с тем эксперименты проводились на одной последовательности с использованием фиксированных периодических стратегий, поэтому полученные зависимости не могут быть обобщены на другие сцены и условия наблюдения без дополнительной проверки.

8 ВЫВОДЫ

В ходе работы проведён анализ современных методов одновременной локализации и картографирования с открытым словарём, рассмотрены особенности их архитектуры, способы формирования метрико-семантического представления среды и подходы к интеграции нейросетевых моделей. На основе проведённого анализа сформулирована концепция адаптивного использования нейросетевых моделей, предполагающая изменение режима семантической обработки в зависимости от информативности поступающих наблюдений и состояния карты. Определены основные критерии оценки эф-

фективности подхода, включающие качество семантического представления, вычислительные затраты и характеристики локализации.

В рамках экспериментальной части развёрнута система OVO, разработан инструмент автоматизированного анализа журналов профилирования и проведено исследование влияния периодичности семантической обработки кадров на качество карты и вычислительную производительность. Эксперименты на последовательности ‘office0’ набора данных Replica показали, что при увеличении периода обработки с 5 до 20 кадров суммарные вычислительные затраты на профилируемые семантические операции сократились на 72,1 %, тогда как значение mIoU увеличилось с 22,80 % до 26,70 %. Установлено, что увеличение количества обрабатываемых кадров не гарантирует повышения качества семантической карты. При этом полученные результаты ограничены одной последовательностью и требуют проверки на других сценах.

Таким образом, результаты аналитического и экспериментального исследования подтверждают целесообразность дальнейшего изучения методов выбора информативных кадров для повышения вычислительной эффективности семантического картографирования. В качестве следующего этапа предполагается исследовать геометрическую и семантическую информативность наблюдений, а также неопределённость формируемой карты как критерии адаптивного управления вычислительными ресурсами. Основной задачей дальнейшей работы является разработка и экспериментальная оценка адаптивной стратегии, обеспечивающей снижение вычислительных затрат при сохранении заданного качества локализации и семантического представления среды.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. *Carlone L., Kim A., Barfoot T., Cremers D., Dellaert F.* SLAM Handbook: From Localization and Mapping to Spatial Intelligence. — Cambridge University Press, 2027. — URL: <https://books.google.ru/books?id=vCR70gEACAAJ>.
2. *Martins T.B., Oswald M.R., Civera J.* Open-Vocabulary Online Semantic Mapping for SLAM // IEEE Robotics and Automation Letters. — 2025. — Nov. — Vol. 10, no. 11. — P. 11745–11752. — arXiv: [2411.15043](https://arxiv.org/abs/2411.15043) [cs.CV]. — URL: <http://arxiv.org/abs/2411.15043> (visited on 09/30/2026).
3. *Ravi N., Gabeur V., Hu Y.-T., [et al.].* SAM 2: Segment Anything in Images and Videos. — 2024. — arXiv: [2408.00714](https://arxiv.org/abs/2408.00714) [cs.CV]. — URL: <https://arxiv.org/abs/2408.00714>.
4. *Zhai X., Mustafa B., Kolesnikov A., Beyer L.* Sigmoid Loss for Language Image Pre-Training. — 2023. — arXiv: [2303.15343](https://arxiv.org/abs/2303.15343) [cs.CV]. — URL: <https://arxiv.org/abs/2303.15343>.
5. *Campos C., Elvira R., Rodriguez J.J.G., M. Montiel J.M., D. Tardos J.* ORB-SLAM3: An Accurate Open-Source Library for Visual, Visual-Inertial, and Multimap SLAM // IEEE Transactions on Robotics. — 2021. — Dec. — Vol. 37, no. 6. — P. 1874–1890. — URL: <http://dx.doi.org/10.1109/TR0.2021.3075644>.
6. *Nasser Z., Iumanov M., Li T., [et al.].* RADIO-ViPE: Online Tightly Coupled Multi-Modal Fusion for Open-Vocabulary Semantic SLAM in Dynamic Environments. — 04/28/2026. — arXiv: [2604.26067](https://arxiv.org/abs/2604.26067) [cs.CV]. — URL: <http://arxiv.org/abs/2604.26067> (visited on 09/18/2026).
7. *Alama O., Jariwala D., Bhattacharya A., [et al.].* RADSeg: Unleashing Parameter and Compute Efficient Zero-Shot Open-Vocabulary Segmentation Using Agglomerative Models. — 2026. — arXiv: [2511.19704](https://arxiv.org/abs/2511.19704) [cs.CV]. — URL: <https://arxiv.org/abs/2511.19704>.
8. *Werby A., Rotondi D., Scaparro F., Arras K.O.* KeySG: Hierarchical Keyframe-Based 3D Scene Graphs. — 03/23/2026. — arXiv: [2510.01049](https://arxiv.org/abs/2510.01049) [cs.CV]. — URL: <http://arxiv.org/abs/2510.01049> (visited on 10/07/2026).

9. *Campello R., Moulavi D., Sander J.* Density-Based Clustering Based on Hierarchical Density Estimates //. Vol. 7819. — 04/2013. — P. 160–172.
10. *Oquab M., Darcet T., Moutakanni T., [et al.].* DINOv2: Learning Robust Visual Features without Supervision. — 2024. — arXiv: [2304.07193](https://arxiv.org/abs/2304.07193) [cs.CV]. — URL: <https://arxiv.org/abs/2304.07193>.
11. *Maggio D., Gorlo N., Hauser K., Carlone L.* FOUND-IT: Foundation-model-first Task-driven 3D Scene Graphs with Granularity on Demand. — 06/09/2026. — arXiv: [2605.25371](https://arxiv.org/abs/2605.25371) [cs.R0]. — URL: <http://arxiv.org/abs/2605.25371> (visited on 10/07/2026).
12. *Maggio D., Carlone L.* VGGT-SLAM 2.0: Real-time Dense Feed-forward Scene Reconstruction. — 2026. — arXiv: [2601.19887](https://arxiv.org/abs/2601.19887) [cs.CV]. — URL: <https://arxiv.org/abs/2601.19887>.
13. *Straub J., Whelan T., Ma L., [et al.].* The Replica Dataset: A Digital Replica of Indoor Spaces // CoRR. — 2019. — Vol. abs/1906.05797.